Control nutricional basado en inteligencia artificial

Autor:
Lic. Sebastián Pardo

Director:
Dr. Facundo Lucianna (FIUBA)

Esta planificación fue realizada en el curso de Gestión de proyectos entre el 3 de marzo de 2026 y el 21 de abril de 2026.

Índice

1. Descripción técnica-conceptual del proyecto a realizar **5**

2. Identificación y análisis de los interesados **6**

3. Propósito del proyecto **7**

4. Alcance del proyecto **7**

5. Supuestos del proyecto **8**

6. Requerimientos **8**

7. Historias de usuarios (*Product backlog*) **10**

8. Entregables principales del proyecto **10**

9. Desglose del trabajo en tareas **11**

10. Diagrama de Activity On Node **12**

11. Diagrama de Gantt **14**

12. Presupuesto detallado del proyecto **17**

13. Gestión de riesgos **17**

14. Gestión de la calidad **20**

15. Procesos de cierre **22**

Registros de cambios

Revisión	Detalles de los cambios realizados	Fecha
0	Creación del documento	3 de marzo de 2026
1	Se completa hasta el punto 5 inclusive	15 de marzo de 2026
2	Se completa hasta el punto 9 inclusive	18 de marzo de 2026
3	Se completa hasta el punto 12 inclusive	30 de marzo de 2026

Acta de constitución del proyecto

Buenos Aires, 3 de marzo de 2026

Por medio de la presente se acuerda con el Lic. Sebastián Pardo que su Trabajo Final de la Carrera de Especialización en Inteligencia Artificial se titulará "Control nutricional basado en inteligencia artificial" y consistirá en el desarrollo de un prototipo de aplicación móvil que utiliza visión por computadora e inteligencia artificial para analizar fotografías de alimentos, identificar sus componentes, estimar porciones y generar registros nutricionales automáticos. El trabajo tendrá un presupuesto preliminar estimado de 680 horas y un costo estimado de $ XXX, con fecha de inicio el 3 de marzo de 2026 y fecha de presentación pública en diciembre 2026.

Se adjunta a esta acta la planificación inicial.

Dr. Ing. Ariel Lutenberg	-
Director posgrado FIUBA	-

Dr. Facundo Lucianna
Director del Trabajo Final

1. Descripción técnica-conceptual del proyecto a realizar

El seguimiento nutricional es una herramienta fundamental en el tratamiento de enfermedades metabólicas, obesidad y otros trastornos relacionados con la alimentación. Sin embargo, los métodos tradicionales, como el diario de comidas manual, recordatorio de 24 horas o cuestionario de frecuencia alimentaria— presentan limitaciones bien documentadas: subestimación sistemática de la ingesta calórica, sesgo de reporte asociado al peso corporal y baja adherencia sostenida en el tiempo. Estudios de revisión sistemática concluyen que todos estos instrumentos tienen sesgos inherentes que comprometen su validez clínica [1]. En intervenciones de pérdida de peso basadas en aplicaciones móviles, la adherencia al registro cae por debajo del 50 % de los participantes ya en la semana 10 [2], y el tiempo requerido para el registro alcanza aproximadamente 23 minutos diarios durante el primer mes [3].

Aplicaciones como MyFitnessPal, Cronometer o Noom han digitalizado parcialmente el proceso, pero siguen dependiendo del ingreso manual de alimentos mediante búsqueda en base de datos, lo que conserva la mayor parte de la fricción original. El reconocimiento automático de alimentos a partir de imágenes representa una alternativa de mayor potencial. Desde el trabajo pionero de Myers et al. [4] (Im2Calories, Google, ICCV 2015), que demostró la factibilidad de estimar calorías a partir de una fotografía tomada con un teléfono, el campo ha avanzado considerablemente. Modelos basados en redes convolucionales (CNN) como DeepFood [5] alcanzaron un 77,4 % de exactitud *top-1* en Food-101, el conjunto de datos de referencia más utilizado (101.000 imágenes, 101 categorías). Con la adopción de Vision Transformers (ViT) y técnicas de aumento de datos, los modelos recientes superan el 91 % en el mismo benchmark [6], y arquitecturas como NoisyViT reportan hasta 99,5 % en condiciones de laboratorio.

No obstante, existe una brecha significativa entre el desempeño en benchmarks controlados y el rendimiento en entornos reales. La validación clínica de la aplicación CALO mama [7] mostró que el sistema estimaba correctamente solo 11 de 30 nutrientes evaluados; y un análisis comparativo de 18 aplicaciones comerciales [8] encontró que los sistemas de IA subestiman sistemáticamente platos de cocinas no occidentales. Dos desafíos técnicos dominan el estado del arte: la **ambigüedad de escala** en imágenes monoculares —sin referencia física no es posible determinar el tamaño real del plato— y la **oclusión** en preparaciones mixtas. Los errores en la estimación de volumen de porciones oscilan entre el 10 % y el 33 % de error relativo [9]. Trabajos recientes como MFP3D [10] abordan este problema mediante reconstrucción de nubes de puntos 3D a partir de imágenes monoculares, mientras que DietAI24 [11] propone integrar modelos de lenguaje multimodal con bases de datos nutricionales para estimar hasta 65 nutrientes desde fotografías.

Este proyecto propone el desarrollo de un prototipo de aplicación móvil que utiliza visión por computadora e inteligencia artificial para analizar imágenes de platos de comida, identificar sus componentes, estimar porciones e integrar los datos nutricionales de forma automática. La solución está orientada a dos perfiles complementarios: el paciente en seguimiento nutricional, que obtiene un registro preciso con mínimo esfuerzo; y el profesional de la nutrición, que accede a datos objetivos para orientar el tratamiento. Se trata de un proyecto personal enmarcado en la Carrera de Especialización en Inteligencia Artificial de la FIUBA, sin vinculación empresarial ni financiamiento externo. El prototipo se ubica en una etapa temprana del ciclo de vida, con foco en validar la factibilidad técnica del enfoque propuesto para el contexto local.

En la figura 1 se presenta el diagrama en bloques del sistema. El flujo comienza con la captura de una fotografía por parte del usuario a través de la aplicación móvil. La imagen es procesada por un módulo de visión por computadora que detecta e identifica los componentes alimentarios

presentes en el plato. Un módulo de estimación de porciones infiere las cantidades a partir de referencias visuales. Con esos datos se consulta una base de datos nutricional para obtener los macronutrientes correspondientes —calorías, proteínas, grasas y carbohidratos— y se genera un registro dietético disponible para el paciente y, en etapas futuras, para el profesional tratante.

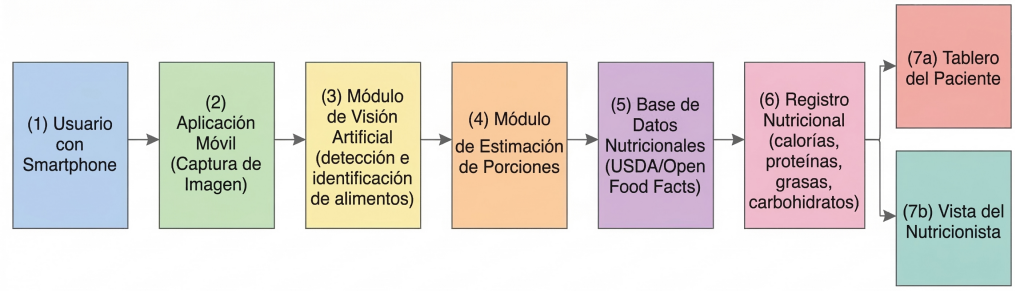

Figura 1. Diagrama en bloques del sistema.

2. Identificación y análisis de los interesados

Rol	Nombre y Apellido	Organización	Puesto
Responsable	Lic. Sebastián Pardo	Independiente	Alumno CEIA–FIUBA
Orientador	Dr. Facundo Lucianna	FIUBA	Director del Trabajo Final
Usuario final	Personas en seguimiento nutricional	-	-
Interesado	Licenciados en Nutrición y Dietistas (AADYND / AALeN)	Asoc. Argentina de Dietistas y Lic. en Nutrición	-
Interesado	Profesionales de Diabetología	Sociedad Argentina de Diabetes (SAD)	-
Interesado	Profesionales de Obesidad y Trastornos Alimentarios	Soc. Argentina de Obesidad y Trast. Alimentarios (SAOTA)	-
Opositor	Aplicaciones de registro nutricional manual	MyFitnessPal, Cronometer, entre otras	-

- Responsable: Lic. Sebastián Pardo es el único miembro del equipo de desarrollo. Gestiona, diseña e implementa el sistema en el marco de la Carrera de Especialización en Inteligencia Artificial de la FIUBA, como profesional independiente sin vinculación institucional.
- Orientador: El Dr. Facundo Lucianna orienta la definición de los requerimientos del sistema, la selección de enfoques técnicos y la evaluación de los resultados del Trabajo Final.

- Usuario final: personas que siguen un plan nutricional y necesitan registrar su ingesta alimentaria de manera precisa y sin fricción. Es el beneficiario primario de la solución.
- Interesado (AADYND / AALeN): la Asociación Argentina de Dietistas y Licenciados en Nutrición agrupa a los profesionales que podrían adoptar la herramienta como complemento en sus prácticas clínicas, o participar en la validación de los registros nutricionales generados.
- Interesado (SAD): la Sociedad Argentina de Diabetes representa a profesionales y pacientes para quienes el control dietético es crítico en el manejo de la enfermedad. Constituye un potencial adoptante institucional en fases avanzadas del producto.
- Interesado (SAOTA): la Sociedad Argentina de Obesidad y Trastornos Alimentarios es el nexo entre profesionales y pacientes en el tratamiento de la obesidad, condición en la que el monitoreo calórico es un componente central del protocolo terapéutico. Podría actuar como validador clínico del sistema.
- Opositor: las aplicaciones de registro manual existentes (MyFitnessPal, Cronometer) tienen bases de usuarios establecidas y podrían representar resistencia al cambio, tanto por parte de los usuarios como de los profesionales que ya las recomiendan en sus consultas.

3. Propósito del proyecto

Facilitar el registro nutricional preciso y de baja fricción mediante inteligencia artificial y visión por computadora, reduciendo la carga cognitiva que representa el seguimiento manual para el paciente y proveyendo a los profesionales de la salud información objetiva que mejore la calidad del acompañamiento dietético.

4. Alcance del proyecto

El proyecto incluye:

- Relevamiento del estado del arte en reconocimiento de alimentos y estimación de porciones mediante visión por computadora.
- Recolección y preparación de un conjunto de datos de imágenes de alimentos etiquetado, adecuado para el entrenamiento y evaluación de los modelos.
- Desarrollo y entrenamiento de un modelo de visión por computadora para la detección e identificación de componentes alimentarios en fotografías.
- Desarrollo de un módulo de estimación de porciones a partir de imágenes.
- Integración con una base de datos nutricional de acceso público para la consulta de macronutrientes (calorías, proteínas, grasas y carbohidratos).
- Desarrollo de un prototipo de aplicación móvil que integre los módulos anteriores, permitiendo al usuario fotografiar su comida y obtener un registro nutricional automático.
- Documentación técnica del sistema y memoria del Trabajo Final.

El presente proyecto no incluye:

- El despliegue en producción ni la publicación en tiendas de aplicaciones (App Store o Google Play).
- El desarrollo de funcionalidades específicas para profesionales de la nutrición (portal clínico, prescripción de dietas, gestión de pacientes).
- La integración con sistemas de gestión clínica (HIS/EHR).
- El soporte multilingüe; el sistema operará exclusivamente en español.
- El desarrollo de un modelo de negocio o funcionalidades de monetización.
- La evaluación clínica formal con pacientes reales.

5. Supuestos del proyecto

Para el desarrollo del presente proyecto se supone que:

- El alumno dispondrá de al menos 15 horas semanales para dedicar al proyecto durante su desarrollo.
- Es técnicamente posible estimar porciones de alimentos a partir de imágenes monoculares con un margen de error aceptable para uso en seguimiento nutricional no clínico.
- Los *datasets* públicos de imágenes de alimentos disponibles (como Food-101 u Open Images) son suficientemente representativos de los alimentos del contexto local para entrenar modelos con precisión aceptable.
- Las bases de datos nutricionales de acceso público (como USDA FoodData Central u Open Food Facts) contienen datos suficientes para cubrir los alimentos más comunes de la dieta argentina.
- El hardware disponible —computadora personal con GPU o acceso a plataformas de cómputo en la nube como Google Colab— será suficiente para el entrenamiento de los modelos requeridos.
- Los usuarios finales disponen de un *smartphone* con cámara de resolución adecuada y acceso a internet.
- El prototipo no requerirá aprobaciones regulatorias durante la etapa de investigación académica.

6. Requerimientos

1. Requerimientos funcionales:

   RF1 La app debe permitir al usuario capturar o seleccionar una fotografía de su comida.

   RF2 El módulo de visión por computadora debe identificar al menos 5 componentes alimentarios distintos en una misma imagen.

RF3 El modelo de CV debe alcanzar una exactitud *top-1* $\geq$ 75 % sobre el conjunto de prueba de imágenes de alimentos locales.

RF4 El módulo de estimación de porciones debe estimar cantidades con un error relativo medio $\leq$ 30 % sobre el conjunto de prueba.

RF5 El sistema debe consultar una base de datos nutricional pública (USDA FoodData Central u Open Food Facts) para obtener los macronutrientes de cada alimento identificado.

RF6 El sistema debe generar y mostrar un resumen nutricional (calorías, proteínas, grasas y carbohidratos) por comida registrada.

RF7 El usuario debe poder consultar su historial nutricional de al menos los últimos 7 días.

RF8 El usuario debe poder corregir los alimentos identificados por el sistema en caso de reconocimiento incorrecto.

RF9 La aplicación debe operar exclusivamente en español.

RF10 El pipeline completo desde la captura de la foto hasta la visualización del resultado nutricional debe completarse en $\leq$ 30 s.

2. Requerimientos de documentación:

RD1 La memoria del Trabajo Final debe seguir las pautas de formato de la CEIA-FIUBA.

RD2 El repositorio de código fuente debe incluir un README con instrucciones de instalación y uso.

RD3 El modelo de CV debe documentarse con su arquitectura, procedimiento de entrenamiento y métricas de evaluación obtenidas.

3. Requerimientos de testing:

RT1 El modelo de CV debe evaluarse sobre un conjunto de prueba representativo de alimentos del contexto local.

RT2 El módulo de estimación de porciones debe probarse con al menos 20 imágenes de referencia.

RT3 El prototipo móvil debe ejecutarse correctamente en al menos un dispositivo iOS físico o simulador.

4. Requerimientos de interfaz:

RI1 La app debe ejecutarse en iOS 15 o posterior.

RI2 La captura o selección de la foto del plato debe requerir $\leq$ 3 interacciones del usuario.

RI3 El resultado nutricional debe mostrarse en la misma sesión de pantalla que la captura fotográfica.

5. Requerimientos de interoperabilidad:

RIO1 El módulo de consulta nutricional debe integrarse con al menos una base de datos nutricional pública mediante API o dataset local.

6. Requerimientos regulatorios:

RReg1 El sistema debe tratar los datos personales de los usuarios (imágenes de alimentos e historial nutricional) en conformidad con la Ley 25.326 de Protección de Datos Personales de la República Argentina.

7. Historias de usuarios (*Product backlog*)

El criterio para calcular los *story points* es: SP = complejidad (1–5) + dificultad (1–5) + incertidumbre (1–5), con un máximo posible de 15 puntos.

1. "Como usuario final, quiero fotografiar mi comida y obtener automáticamente su contenido nutricional, para registrar mi ingesta sin necesidad de búsqueda manual."

   Story points: 13 (complejidad: 5, dificultad: 4, incertidumbre: 4)

2. "Como usuario final, quiero ver los macronutrientes de cada comida registrada, para monitorear si estoy cumpliendo mi plan dietético."

   Story points: 3 (complejidad: 1, dificultad: 1, incertidumbre: 1)

3. "Como usuario final, quiero consultar mi historial nutricional de los últimos 7 días, para hacer seguimiento de mi progreso a lo largo del tiempo."

   Story points: 4 (complejidad: 2, dificultad: 1, incertidumbre: 1)

4. "Como usuario final, quiero poder corregir los alimentos identificados por el sistema cuando el reconocimiento sea incorrecto, para asegurar la exactitud de mis registros."

   Story points: 6 (complejidad: 2, dificultad: 2, incertidumbre: 2)

5. "Como investigador/desarrollador, quiero evaluar la precisión del modelo con imágenes de comidas locales, para validar que el sistema sea adecuado para el contexto dietético argentino."

   Story points: 8 (complejidad: 3, dificultad: 3, incertidumbre: 2)

8. Entregables principales del proyecto

Los entregables del proyecto son:

1. Modelo de CV entrenado para identificación de alimentos (pesos del modelo y métricas de evaluación).
2. Módulo de estimación de porciones (código fuente y métricas de evaluación).
3. Prototipo de aplicación móvil iOS funcional.
4. Dataset de imágenes de alimentos etiquetado, utilizado para entrenamiento y evaluación.
5. Capa de integración con base de datos nutricional (código fuente).
6. Memoria del Trabajo Final (documento en formato CEIA-FIUBA).
7. Repositorio de código fuente versionado con README e instrucciones de uso.

9. Desglose del trabajo en tareas

1. Gestión del proyecto (30 h)
   - 1.1. Planificación inicial y Plan de Proyecto — GdP (20 h)
   - 1.2. Seguimiento y control periódico (10 h)
2. Investigación y estado del arte (60 h)
   - 2.1. Revisión bibliográfica de reconocimiento de alimentos con CV (25 h)
   - 2.2. Revisión bibliográfica de estimación de porciones monoculares (20 h)
   - 2.3. Análisis y selección de datasets y herramientas (15 h)
3. Datos: recolección y preparación (80 h)
   - 3.1. Descarga y análisis de datasets públicos (Food-101, Open Images) (20 h)
   - 3.2. Limpieza y filtrado de datos (15 h)
   - 3.3. Recolección y anotación de imágenes locales (30 h)
   - 3.4. Desarrollo del pipeline de preprocesamiento (15 h)
4. Modelo de reconocimiento de alimentos (130 h)
   - 4.1. Selección y configuración del modelo base (ViT / CNN) (20 h)
   - 4.2. Entrenamiento inicial — *fine-tuning* sobre dataset base (30 h)
   - 4.3. Evaluación del modelo (métricas *top-1*, *top-5*) (20 h)
   - 4.4. Iteraciones de mejora y ajuste de hiperparámetros (40 h)
   - 4.5. Documentación técnica del modelo (20 h)
5. Módulo de estimación de porciones (100 h)
   - 5.1. Investigación de técnicas de estimación de volumen monocular (20 h)
   - 5.2. Implementación del módulo de estimación (40 h)
   - 5.3. Evaluación del módulo (error relativo sobre set de prueba) (20 h)
   - 5.4. Integración con el módulo de reconocimiento (20 h)
6. Integración con base de datos nutricional (50 h)
   - 6.1. Evaluación de bases de datos disponibles (USDA, Open Food Facts) (15 h)
   - 6.2. Desarrollo de la capa de consulta/wrapper (20 h)
   - 6.3. Mapeo y validación de alimentos a entradas de la BD (15 h)
7. Aplicación móvil iOS (100 h)
   - 7.1. Diseño de la interfaz de usuario (wireframes y flujo de navegación) (20 h)
   - 7.2. Desarrollo del frontend iOS (SwiftUI o React Native) (40 h)
   - 7.3. Integración del backend de IA con la app (25 h)
   - 7.4. Pruebas de integración y correcciones (15 h)
8. Documentación y memoria del Trabajo Final (130 h)
   - 8.1. Redacción de la memoria (versión 1) (25 h)

8.2. Revisión y corrección con el director (versión 2) (50 h)
8.3. Versión final y preparación de la presentación (30 h)
8.4. Preparación y práctica de la defensa oral (25 h)

Cantidad total de horas: 680 h.

10. Diagrama de Activity On Node

En las figuras **??** a **??** se presenta el diagrama *Activity on Node* construido a partir del WBS de la sección 9. Los tiempos están expresados en horas. Los nodos del camino crítico se indican en rojo.

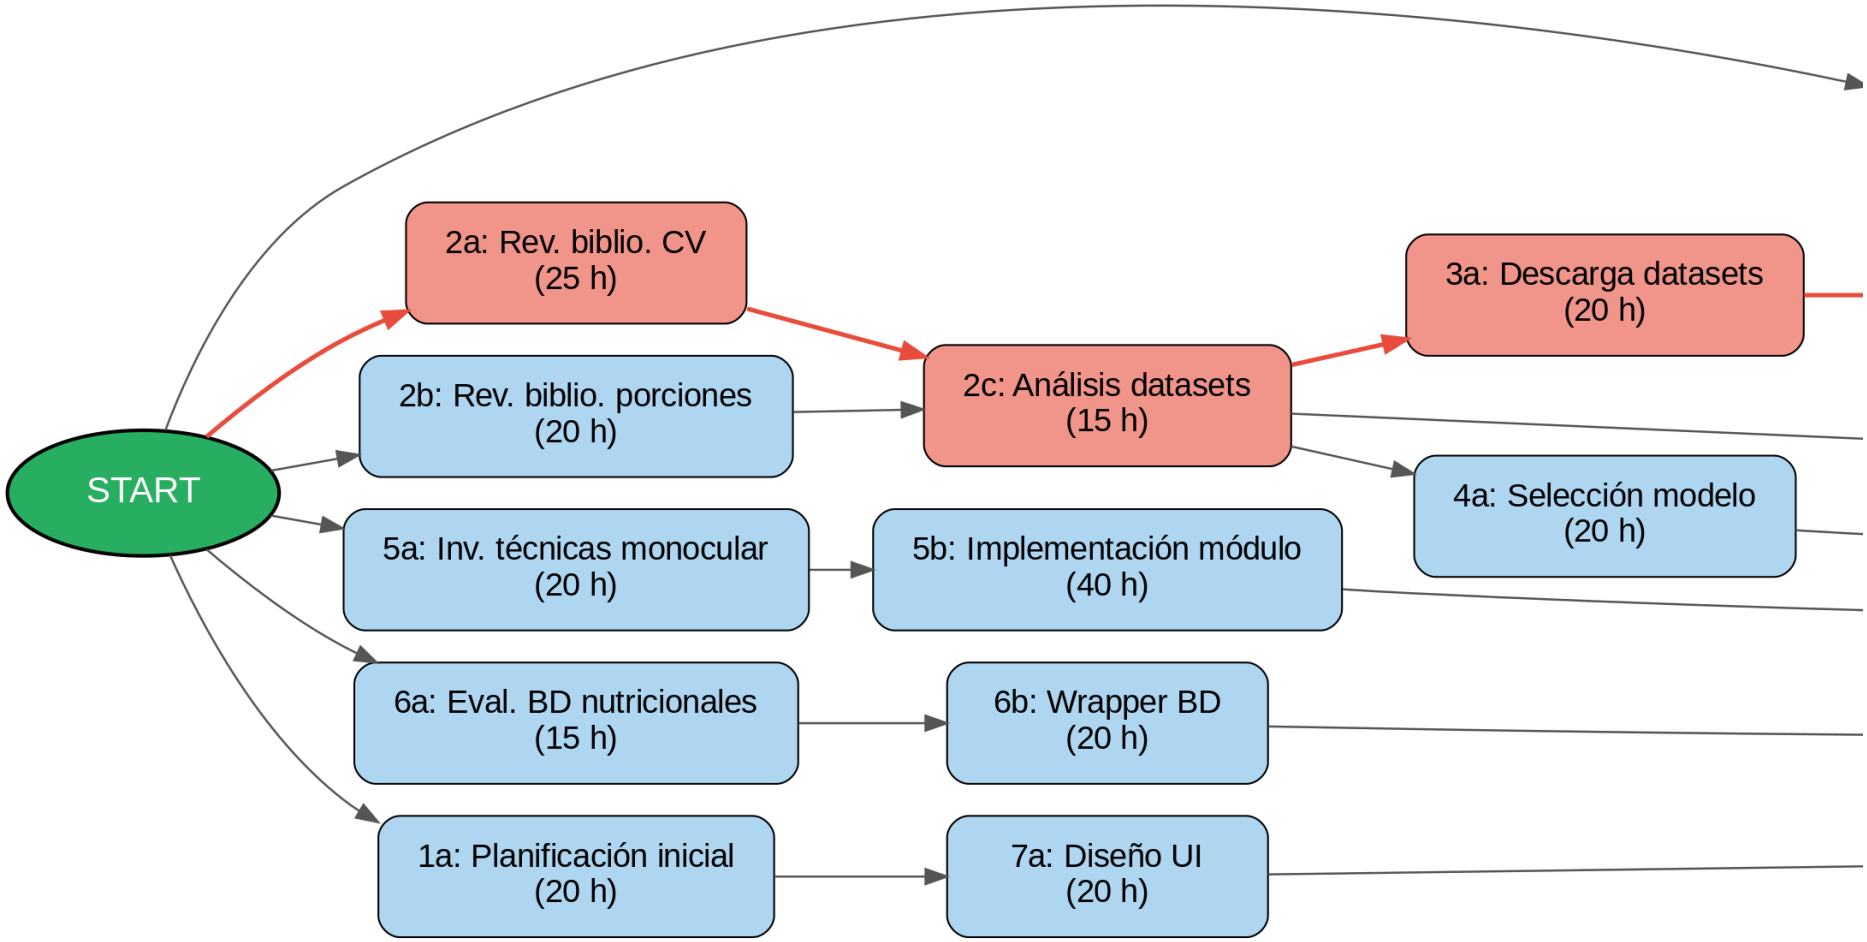

Figura 2. Diagrama de *Activity on Node* (1/4). Tiempos en horas.

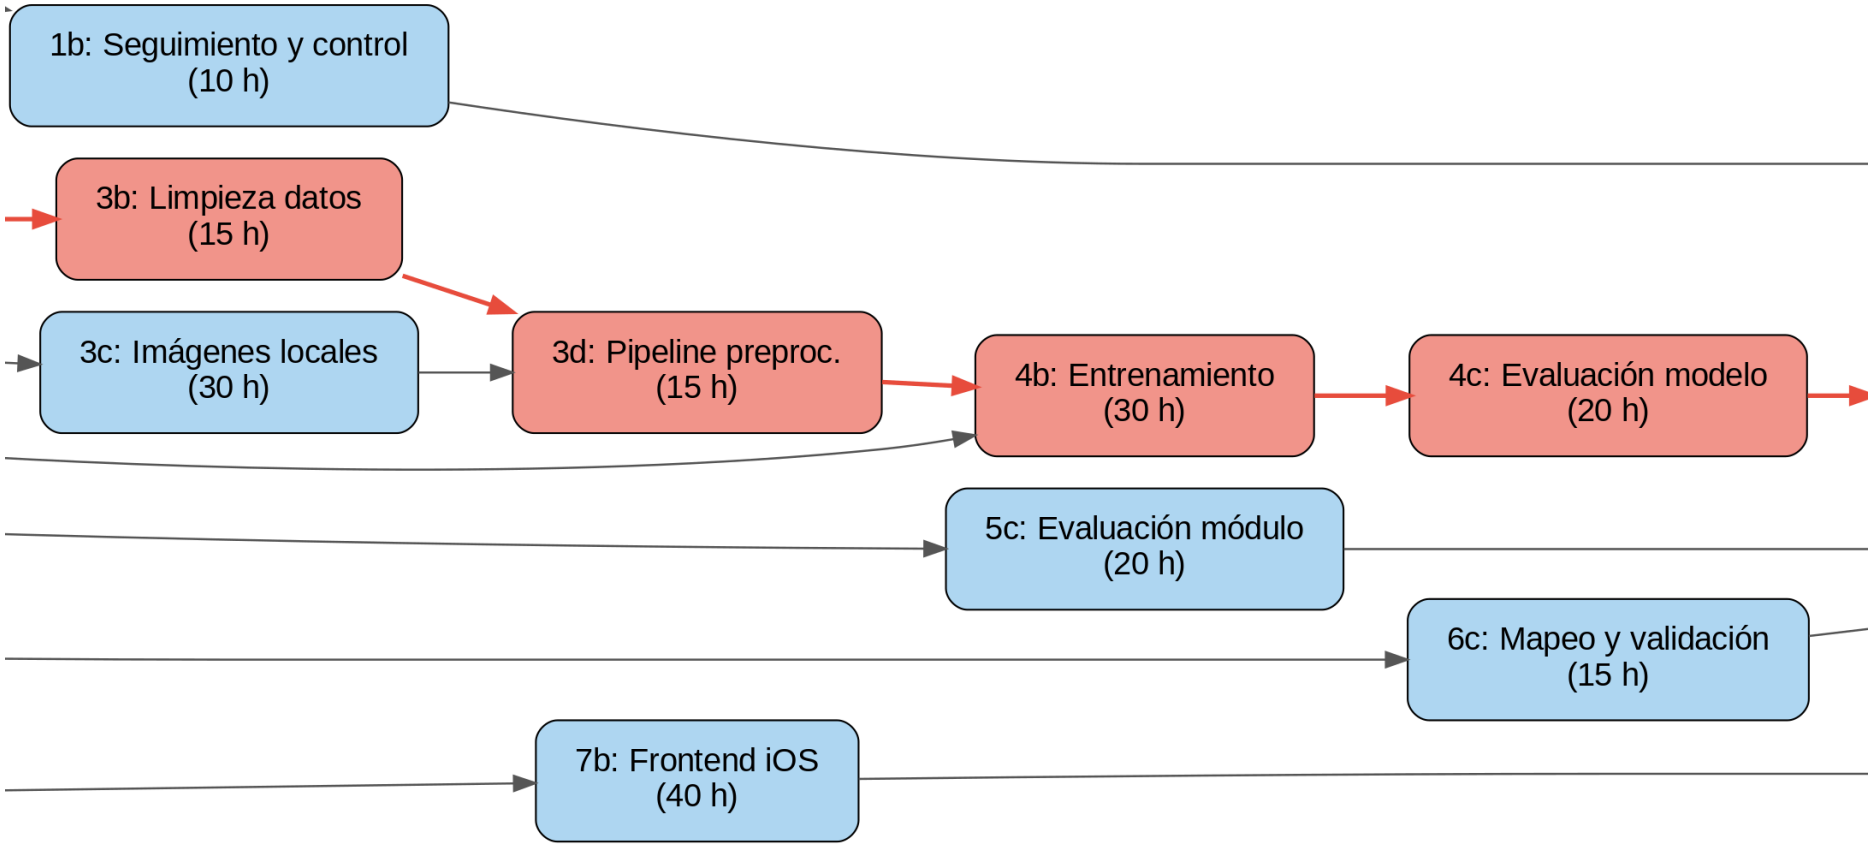

Figura 3. Diagrama de *Activity on Node* (2/4).

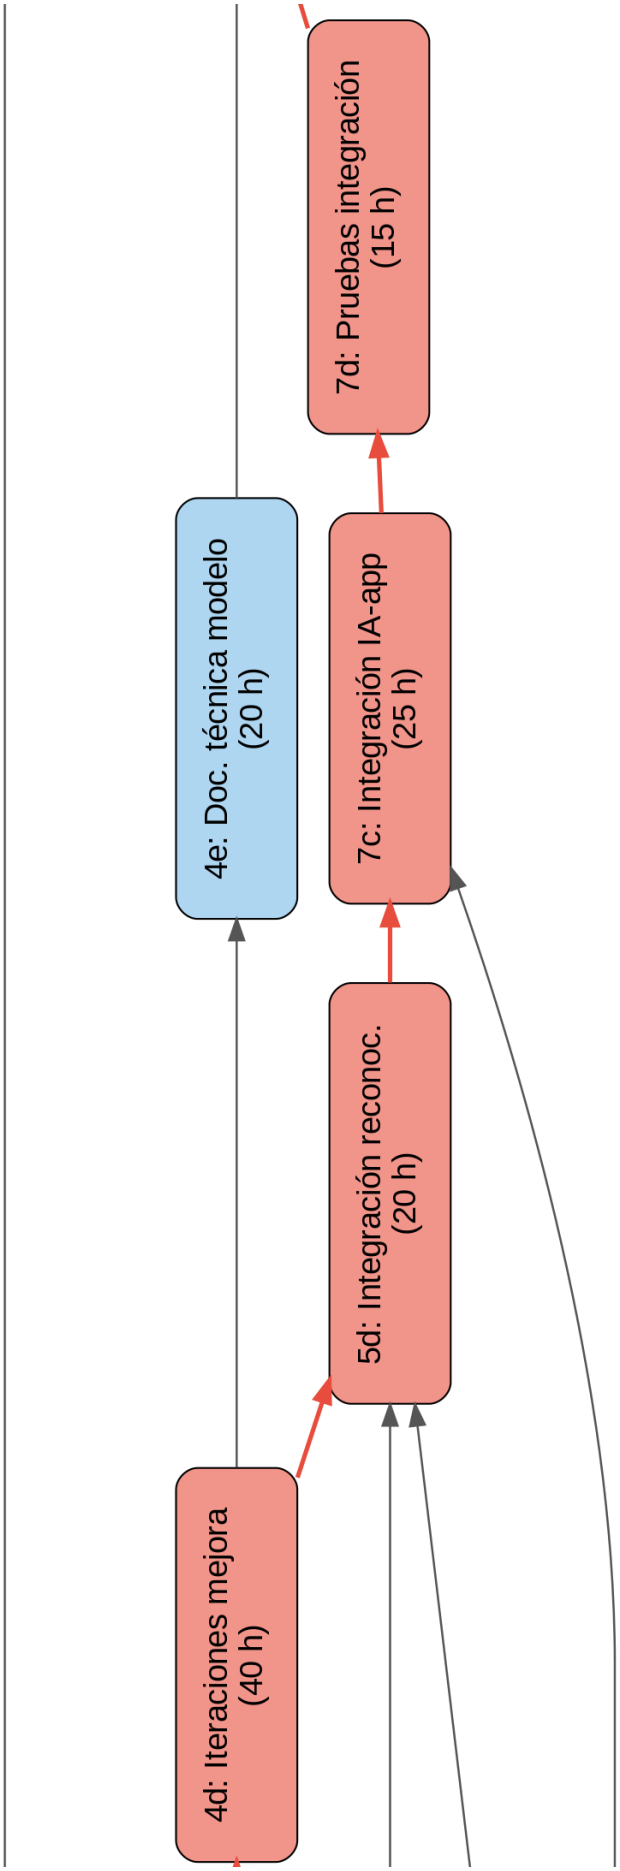

Figura 4. Diagrama de *Activity on Node* (3/4).

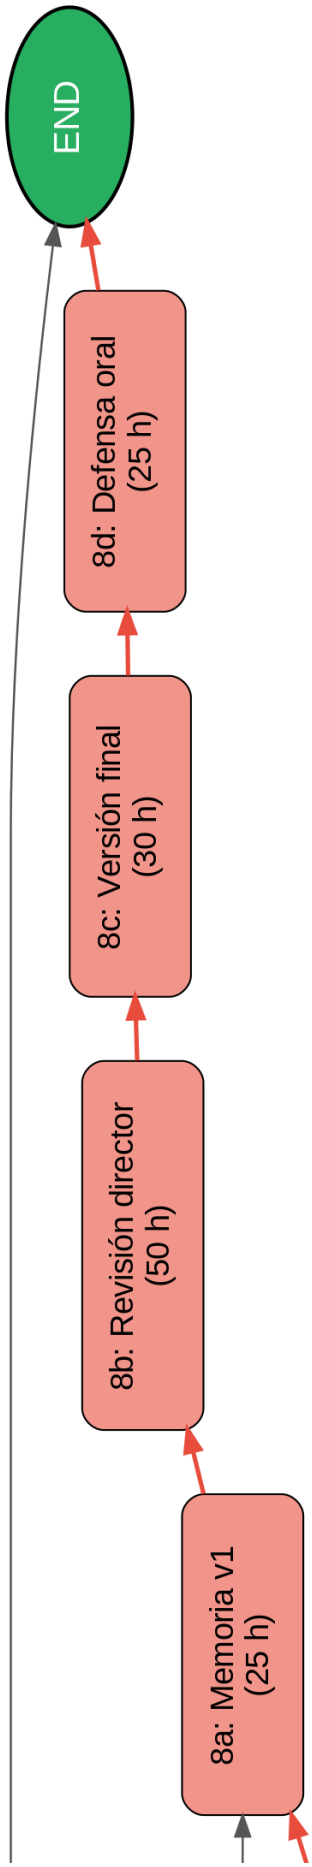

Figura 5. Diagrama de *Activity on Node* (4/4). Camino crítico (rojo): 2a → 2c → 3a → 3b → 3d → 4b → 4c → 4d → 5d → 7c → 7d → 8a → 8b → 8c → 8d, con una duración acumulada de 370 h.

El camino crítico tiene una duración de 370 h. La tabla 1 resume el camino crítico y los dos caminos semicríticos con mayor duración.

Cuadro 1. Camino crítico y caminos semicríticos (duración en horas).

Camino	Secuencia de tareas	Dur. (h)	Holgura
Crítico	2a → 2c → 3a → 3b → 3d → 4b → 4c → 4d → 5d → 7c → 7d → 8a → 8b → 8c → 8d	370	0 h
Semicrítico 1	**2b** → 2c → 3a → 3b → 3d → 4b → 4c → 4d → 5d → 7c → 7d → 8a → 8b → 8c → 8d	365	5 h
Semicrítico 2	2a → 2c → **3c** → 3d → 4b → 4c → 4d → 5d → 7c → 7d → 8a → 8b → 8c → 8d	365	5 h

11. Diagrama de Gantt

En las figuras 3 y 4 se presenta el diagrama de Gantt del proyecto. Las unidades de tiempo son días calendario y la disponibilidad estimada es de 15 h semanales, lo que equivale a 680 h totales en aproximadamente 45 semanas (3 de marzo de 2026 al 20 de enero de 2027). Los colores identifican cada grupo de tareas del WBS.

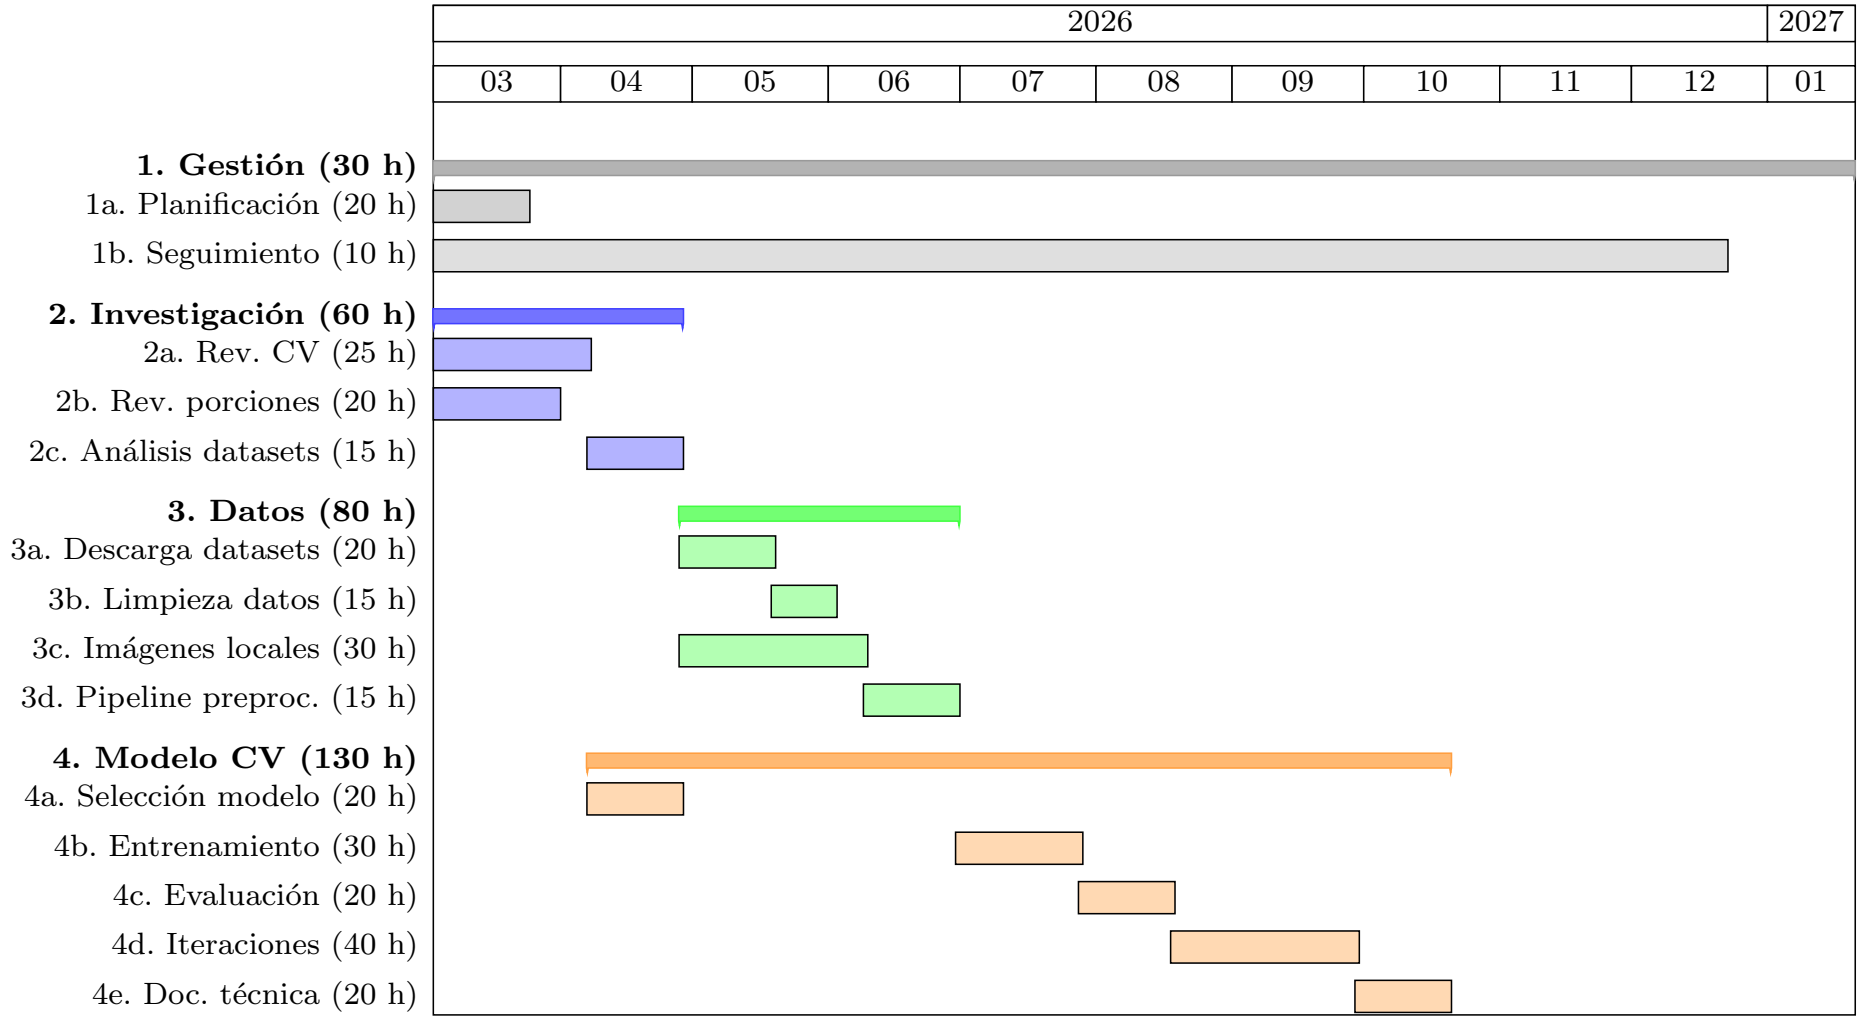

Figura 6. Diagrama de Gantt, parte 1/2: grupos 1–4 (3 de marzo de 2026 – 20 de enero de 2027). Unidades: días calendario. Disponibilidad: 15 h semanales. Colores: ■ Gestión, ■ Investigación, ■ Datos, ■ Modelo CV.

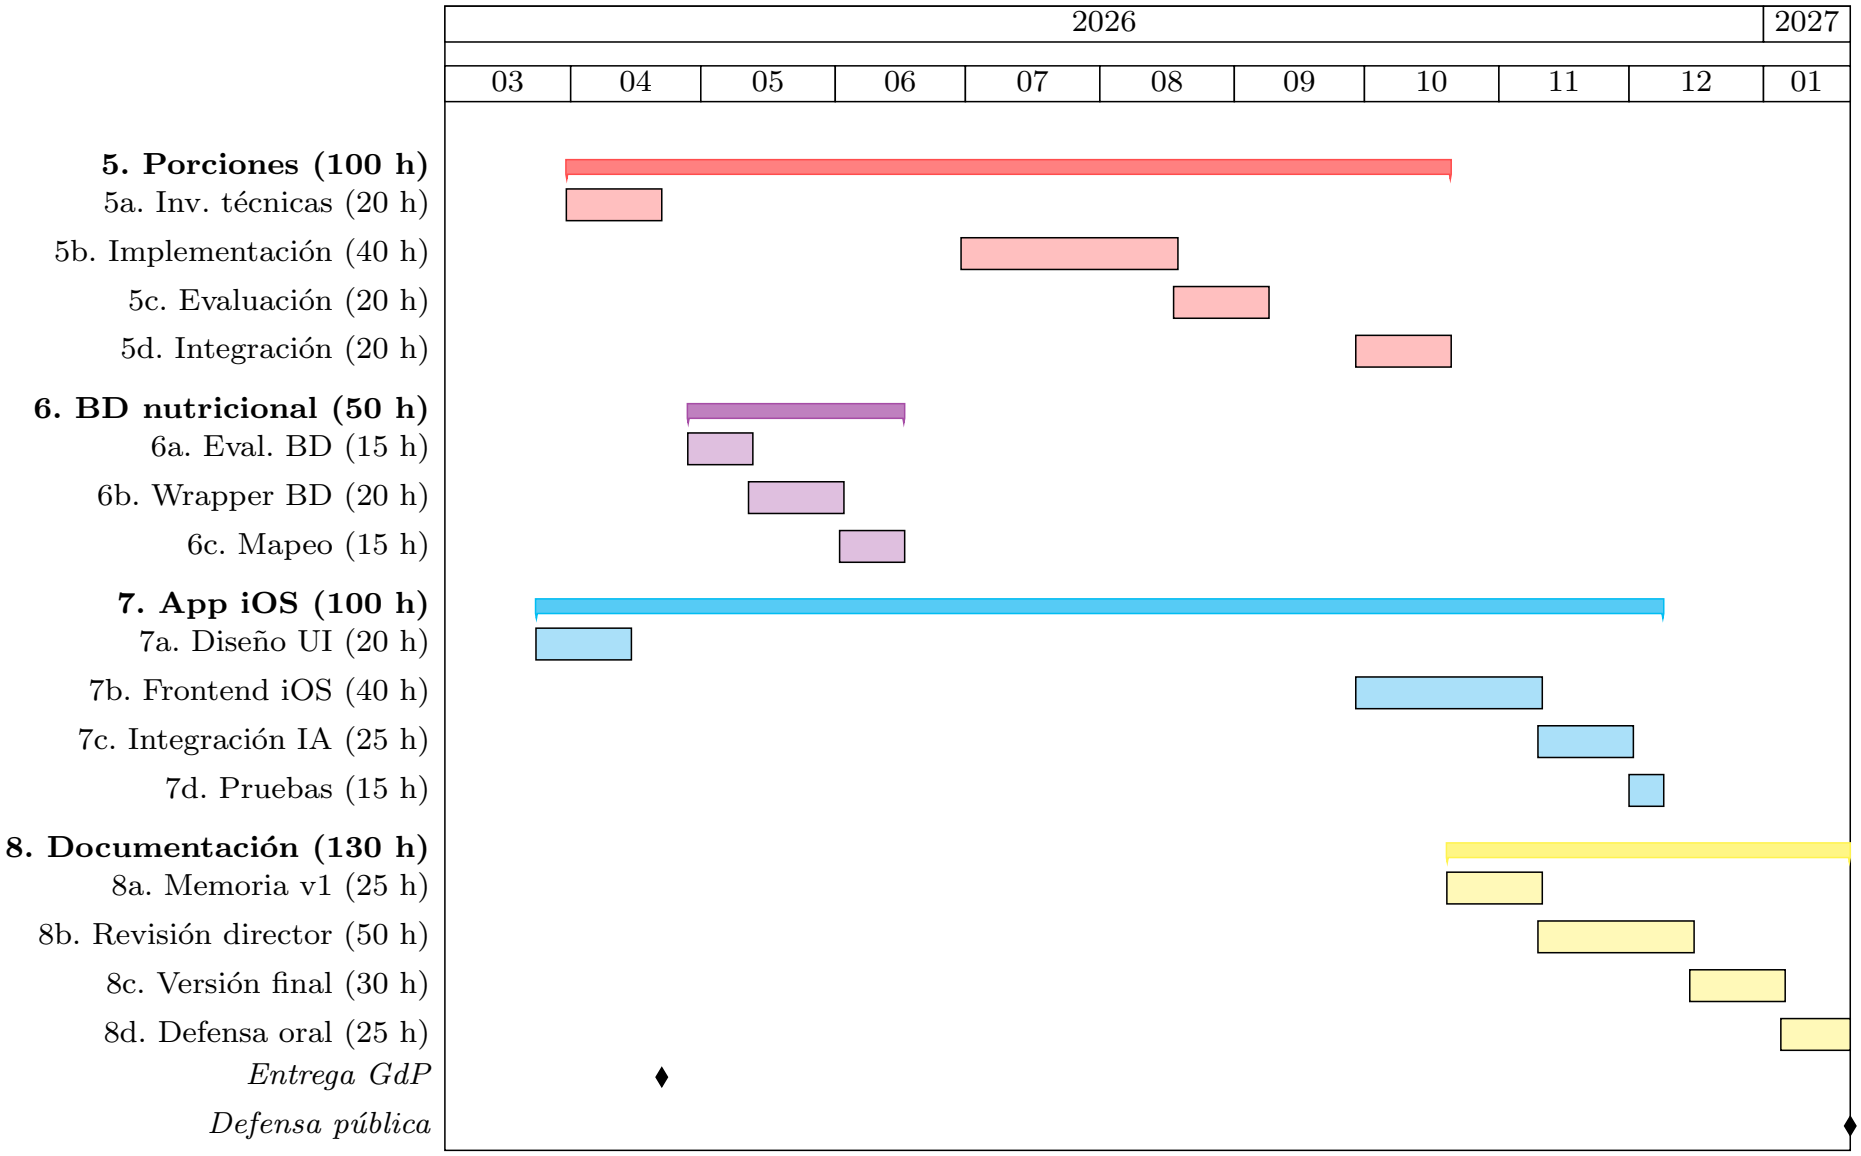

Figura 7. Diagrama de Gantt, parte 2/2: grupos 5–8 (3 de marzo de 2026 – 20 de enero de 2027). Unidades: días calendario. Disponibilidad: 15 h semanales. Colores: Porciones, BD nutricional, App iOS, Documentación.

12. Presupuesto detallado del proyecto

Los costos se expresan en pesos argentinos (ARS). La tabla detalla los costos directos e indirectos del proyecto. Los costos indirectos se estiman como el 20 % del subtotal directo. Los ítems sin costo adicional (licencias de software, dispositivo iOS propio y acceso bibliográfico institucional/arXiv) no se incluyen en la tabla ya que no generan erogaciones.

COSTOS DIRECTOS			
Descripción	Cantidad	Valor unitario (ARS)	Valor total (ARS)
Cómputo GPU en la nube (Google Colab Pro, USD 9,99/mes*)	9 meses	$ 14.136/mes	$ 127.224
SUBTOTAL DIRECTO			$ 127.224
COSTOS INDIRECTOS			
Descripción	Cantidad	Valor unitario (ARS)	Valor total (ARS)
Electricidad e internet (parte proporcional**)	9 meses	$ 8.560/mes	$ 77.040
Amortización de hardware (MacBook Pro M1 16 GB, vida útil 5 años***)	9 meses	$ 30.833/mes	$ 277.497
SUBTOTAL INDIRECTO			$ 354.537
TOTAL			$ 481.761

13. Gestión de riesgos

a) Identificación de los riesgos y estimación de sus consecuencias:

Riesgo 1: Baja representatividad de los *datasets* públicos para alimentos del contexto local argentino. Los conjuntos de datos públicos como Food-101 contienen predominantemente alimentos de cocinas occidentales anglosajonas y tienen escasa cobertura de platos típicos argentinos (empanadas, locro, asado, milanesas). Si el modelo se entrena sin imágenes locales suficientes, su precisión real en producción podría ser considerablemente menor a la observada sobre el *benchmark* estándar, comprometiendo RF3.

- Severidad (S): 7. Un modelo que no reconoce alimentos locales pierde la mayor parte de su utilidad para el usuario objetivo, que registra mayoritariamente gastronomía argentina.
- Ocurrencia (O): 7. Es muy probable dado que los *datasets* públicos de referencia fueron construidos en contextos anglosajones y la proporción de platos locales es marginal.

Riesgo 2: Rendimiento insuficiente del modelo de CV (*top-1* $<$ 75 % sobre imágenes locales). Aunque los modelos modernos superan el 91 % en Food-101, su transferencia a imágenes locales con menor volumen de datos puede resultar en una performance significativamente inferior. El incumplimiento de RF3 implicaría rediseñar la estrategia de modelo o de datos, con impacto directo en el cronograma.

- Severidad (S): 8. Incumplir el requerimiento central del sistema impide validar la hipótesis técnica del proyecto y compromete la totalidad de los entregables dependientes.

- Ocurrencia (O): 5. Existe evidencia en el estado del arte de una brecha entre *benchmarks* controlados y desempeño real (CALO mama estimó correctamente solo 11 de 30 nutrientes evaluados [7]).

Riesgo 3: Error en la estimación de porciones superior al límite establecido ($> 30\,\%$). La estimación de volumen a partir de imágenes monoculares sin referencia física es uno de los problemas más abiertos del estado del arte; los errores reportados oscilan entre el 10 % y el 33 % [9]. Es posible que no se alcance el umbral de RF4 con las técnicas seleccionadas.

- Severidad (S): 7. Sin estimación de porciones confiable el valor nutricional calculado es inexacto, reduciendo la utilidad clínica del sistema para seguimiento dietético.
- Ocurrencia (O): 6. El límite del 30 % se sitúa en el extremo superior del rango reportado en la literatura para imágenes monoculares sin referencia.

Riesgo 4: Disponibilidad de tiempo efectiva por debajo de las 15 h semanales comprometidas. El proyecto se desarrolla de forma individual en paralelo a compromisos laborales. Imprevistos laborales o personales podrían reducir la disponibilidad real, generando retrasos en el cronograma, especialmente en las tareas del camino crítico.

- Severidad (S): 5. Un retraso acumulado de varias semanas afectaría tareas del camino crítico, aunque algunas actividades disponen de holgura suficiente para absorber demoras moderadas.
- Ocurrencia (O): 4. Moderadamente probable dado el contexto de trabajo profesional simultáneo durante todo el período del proyecto.

Riesgo 5: Latencia del *pipeline* completo mayor a 30 s en dispositivo móvil. El *pipeline* integra inferencia CV + estimación de porciones + consulta de BD nutricional. En un *smartphone* sin GPU dedicada, la inferencia local de un modelo ViT podría superar el requisito de RF10 y degradar significativamente la experiencia de usuario.

- Severidad (S): 6. Superar los 30 s desmotiva el uso cotidiano del sistema, que depende de la adherencia del usuario para su valor como herramienta de seguimiento.
- Ocurrencia (O): 5. Los modelos ViT tienen alta demanda computacional; sin optimización (cuantización, ejecución en servidor) es probable que superen el umbral en dispositivos de gama media.

Riesgo 6: Descontinuación o cambio *breaking* en la API de la base de datos nutricional pública. USDA FoodData Central y Open Food Facts han experimentado cambios en sus APIs en el pasado. Una modificación durante el desarrollo podría inutilizar la capa de integración implementada.

- Severidad (S): 4. Afecta la integración pero es relativamente sencillo adaptar la capa de consulta a otra fuente de datos o a una versión actualizada de la API.

- Ocurrencia (O): 3. Los cambios *breaking* en estas APIs son poco frecuentes, pero posibles en un horizonte de desarrollo de 10 meses.

b) Tabla de gestión de riesgos (RPN = S × O):

Riesgo	S	O	RPN	S*	O*	RPN*
1. Datasets no representativos de cocina local	7	7	49	7	3	21
2. Rendimiento insuficiente del modelo de CV	8	5	40	8	3	24
3. Error de estimación de porciones > 30 %	7	6	42	7	3	21
4. Disponibilidad de tiempo < 15 h/semana	5	4	20	-	-	-
5. Latencia del *pipeline* > 30 s	6	5	30	6	2	12
6. Cambio *breaking* en API de BD nutricional	4	3	12	-	-	-

Criterio adoptado: se tomarán medidas de mitigación en los riesgos cuyos RPN sean mayores a **25**. Con este criterio, los riesgos 1, 2, 3 y 5 requieren plan de mitigación. Los valores marcados con (*) corresponden luego de haber aplicado la mitigación.

c) Plan de mitigación de los riesgos que superan el RPN máximo establecido:

Riesgo 1 — plan de mitigación. Se dedicará la tarea 3c del WBS (30 h) a la recolección y anotación manual de imágenes de platos típicos argentinos. Se aplicarán técnicas de *data augmentation* específicas para estas categorías (rotación, cambios de iluminación, recortes) a fin de ampliar artificialmente el subconjunto local. El modelo se evaluará sobre un *test set* exclusivamente compuesto por imágenes locales.

- Severidad (S*): 7. La severidad no cambia; si el modelo igualmente falla en alimentos locales, el impacto es el mismo.
- Ocurrencia (O*): 3. La recolección activa de imágenes locales reduce considerablemente la probabilidad de que el dataset sea insuficiente para el contexto objetivo.

Riesgo 2 — plan de mitigación. Se planificarán iteraciones explícitas de ajuste de hiperparámetros y experimentación con arquitecturas alternativas (tarea 4d, 40 h). Se definirán criterios de aceptación intermedios en cada hito de evaluación. Si al finalizar las iteraciones no se alcanza el umbral del 75 %, la limitación se documenta formalmente en la memoria y se propone como trabajo futuro.

- Severidad (S*): 8. No cambia; incumplir el requerimiento principal sigue siendo severo.
- Ocurrencia (O*): 3. Las iteraciones planificadas y la estrategia de documentar como limitación (en lugar de dejar el requerimiento sin tratamiento) reducen el riesgo de que la situación quede sin respuesta.

Riesgo 3 — plan de mitigación. Durante la tarea 5a (investigación de técnicas, 20 h) se priorizará el estudio de métodos con referencia visual. El diseño de la interfaz de la app incorporará la opción de incluir un objeto de referencia de tamaño conocido (moneda de $10, cubierto estándar) en el encuadre del plato para resolver la ambigüedad de escala. Si aun así el error supera el 30 %, se documentará la limitación y se propone trabajo futuro con sensores de profundidad (LiDAR disponible en modelos iPhone Pro).

- Severidad (S*): 7. No cambia; el impacto sigue siendo alto si el error es excesivo.
- Ocurrencia (O*): 3. La referencia física en imagen elimina el principal factor de error en la estimación monocular, reduciendo sustancialmente la probabilidad de superar el umbral.

Riesgo 5 — plan de mitigación. El *pipeline* de inferencia se diseñará con arquitectura cliente-servidor: la app móvil envía la imagen a un *backend* REST (desplegado en la nube, p. ej. Google Cloud Run) que ejecuta los modelos y retorna el resultado. Esto traslada la carga computacional fuera del dispositivo y hace la latencia predecible y controlable. Se acepta la dependencia de conectividad como condición de uso del prototipo.

- Severidad (S*): 6. No cambia; una latencia elevada seguiría siendo problemática.
- Ocurrencia (O*): 2. La arquitectura cliente-servidor hace que la latencia dependa principalmente del ancho de banda de red, que puede optimizarse independientemente del modelo, tornando muy improbable superar los 30 s en condiciones normales.

14. Gestión de la calidad

Se seleccionaron los diez requerimientos de mayor criticidad para el proyecto. Las acciones de verificación tratan al sistema como caja blanca; las de validación, como caja negra.

- **RF1** — La app debe permitir al usuario capturar o seleccionar una fotografía de su comida.
  - Verificación: prueba unitaria del componente de captura/selección en el simulador iOS. Se verifica que el flujo de `PhotosUI` retorna correctamente un objeto imagen en ambos modos (cámara y biblioteca de fotos), incluyendo el caso de rechazo de permiso.
  - Validación: sesión de prueba de usabilidad con tres usuarios representativos. Se observa que cada uno logra fotografiar o seleccionar un plato sin asistencia ni instrucciones adicionales en el primer intento.
- **RF2** — El módulo de CV debe identificar al menos 5 componentes alimentarios distintos en una misma imagen.
  - Verificación: se construye un conjunto de 10 imágenes de platos compuestos (ensalada mixta, puchero, picada, etc.) con al menos 5 componentes etiquetados cada una. Se verifica que el modelo devuelve $\geq$5 detecciones con confianza $\geq$0,5 en todos los casos.
  - Validación: un licenciado en nutrición evalúa los resultados sobre 3 imágenes de platos típicos y confirma que los componentes identificados corresponden visualmente a los alimentos presentes en el plato.
- **RF3** — El modelo de CV debe alcanzar exactitud *top-1* $\geq$ 75 % sobre el conjunto de prueba de imágenes locales.
  - Verificación: evaluación del modelo entrenado sobre un *test set* estratificado y no contaminado de imágenes locales etiquetadas. Se calcula la exactitud *top-1* y *top-5* y se registran en el informe técnico (RD3). Se verifica que el valor *top-1* supera el umbral.

- Validación: el director del trabajo revisa la metodología de evaluación, el tamaño del *test set* y la ausencia de contaminación con los datos de entrenamiento, y confirma la validez del resultado.

- **RF4** — El módulo de estimación de porciones debe estimar cantidades con error relativo medio $\leq$ 30 %.
  - Verificación: se construye un conjunto de prueba de $\geq$20 imágenes con porciones previamente pesadas en balanza de cocina calibrada. Se calcula el error relativo medio $\overline{|e_r|} = \frac{1}{n}\sum \frac{|\hat{p}_i - p_i|}{p_i}$ y se verifica que sea $\leq$30 %.
  - Validación: se presentan al director 5 casos de estimación seleccionados aleatoriamente del conjunto de prueba, con imagen, estimación del sistema y valor real de referencia. El director confirma que el procedimiento de medición es reproducible y representativo.

- **RF6** — El sistema debe generar y mostrar un resumen nutricional (calorías, proteínas, grasas y carbohidratos) por comida registrada.
  - Verificación: prueba de integración *end-to-end* con 5 alimentos de referencia presentes en la BD nutricional. Se verifica que el sistema retorna valores numéricos para los cuatro macronutrientes y que coinciden con los de la fuente (tolerancia $\pm$1 % por redondeo en punto flotante).
  - Validación: un licenciado en nutrición compara el resumen nutricional generado para 3 comidas tipo con los valores de referencia que conoce de su práctica profesional, y confirma que son plausibles y útiles para seguimiento dietético.

- **RF7** — El usuario debe poder consultar su historial nutricional de al menos los últimos 7 días.
  - Verificación: prueba funcional en simulador con registros simulados de 8 días. Se verifica que todos los registros de los últimos 7 días son visibles, correctamente ordenados cronológicamente, y que los registros anteriores a 7 días no se muestran por defecto.
  - Validación: en la sesión de prueba de usabilidad, se solicita a un usuario que navegue al historial tras registrar varias comidas. Se observa que accede a sus registros anteriores sin asistencia.

- **RF8** — El usuario debe poder corregir los alimentos identificados por el sistema en caso de reconocimiento incorrecto.
  - Verificación: prueba funcional en simulador que simula una identificación incorrecta. Se verifica que: (a) el usuario puede seleccionar un alimento distinto desde una lista de búsqueda, (b) el registro nutricional se recalcula correctamente, y (c) la corrección queda persistida en el historial.
  - Validación: en la sesión de usabilidad, se presenta un caso donde el sistema identifica incorrectamente un alimento. Se observa que el usuario comprende el mecanismo de corrección, puede aplicarlo sin instrucciones y queda satisfecho con el resultado.

- **RF10** — El *pipeline* completo desde la captura hasta la visualización del resultado nutricional debe completarse en $\leq$ 30 s.
  - Verificación: se instrumenta la app con registro de tiempos entre el *tap* en "analizar" y la presentación del resumen nutricional. Se ejecutan 10 mediciones en condiciones de red Wi-Fi estándar (50 Mbps) y se registran el tiempo promedio y el percentil 90. Ambos deben ser $\leq$30 s.

  - Validación: demostración en vivo ante el director del trabajo con una imagen real de un plato. El director evalúa subjetivamente que la espera es aceptable para un uso cotidiano.

- **RI2** — La captura o selección de la foto del plato debe requerir ≤ 3 interacciones del usuario.
  - Verificación: inspección del flujo de navegación en el prototipo. Se cuenta el número de toques desde la pantalla principal hasta la confirmación de la fotografía y se verifica que no supera 3 en ninguno de los dos modos posibles (cámara o biblioteca).
  - Validación: en la sesión de usabilidad con tres usuarios, se verifica que ninguno necesita más de 3 interacciones para fotografiar un plato y que ninguno solicita ayuda durante esta acción.

- **RReg1** — El sistema debe tratar los datos personales en conformidad con la Ley 25.326 de Protección de Datos Personales.
  - Verificación: revisión del código fuente de la app y del *backend*. Se verifica que: (a) las imágenes y registros nutricionales se transmiten únicamente mediante HTTPS, (b) no se envían datos personales a servicios de terceros sin consentimiento explícito del usuario, y (c) el usuario puede eliminar la totalidad de su historial desde la interfaz.
  - Validación: el director del trabajo revisa las medidas técnicas implementadas y confirma que son coherentes con los requisitos de la ley. Se documenta esta revisión en la memoria del Trabajo Final.

15. Procesos de cierre

- **Análisis de adherencia al Plan de Proyecto original.** El responsable del proyecto (Lic. Sebastián Pardo) realizará, en los 15 días posteriores a la defensa oral, una reunión de cierre con el director (Dr. Facundo Lucianna). El procedimiento consistirá en contrastar el diagrama de Gantt original con las fechas reales de finalización de cada tarea del WBS, calculando la variación de cronograma (SV = tiempo planificado − tiempo real) para cada grupo de tareas. Se verificará además si el alcance definido en la sección 4 fue respetado, documentando cualquier tarea incorporada o eliminada durante la ejecución. Los resultados de este análisis quedarán registrados como un documento de cierre en el repositorio del proyecto.

- **Identificación de técnicas, problemas y lecciones aprendidas.** El responsable elaborará un documento de lecciones aprendidas en los 15 días posteriores a la defensa. El documento incluirá:

  a) Lista de herramientas, bibliotecas y enfoques técnicos empleados, con evaluación de su utilidad real (útil / parcialmente útil / no útil) y justificación breve.

  b) Descripción de los problemas más significativos que surgieron durante el desarrollo (técnicos, de datos, de cronograma) y cómo fueron resueltos o gestionados.

  c) Recomendaciones para futuros trabajos que aborden sistemas similares de reconocimiento de alimentos en contextos locales.

  Este documento quedará como anexo del repositorio de código fuente (sección `docs/lecciones_aprendidas.md`) y como parte de la memoria del Trabajo Final.

- **Acto de agradecimiento.** El responsable del proyecto organizará un encuentro informal (desayuno o almuerzo) de agradecimiento destinado al director del Trabajo Final, a los colaboradores que participaron en la recolección y anotación de imágenes locales, y a los licenciados en nutrición que colaboraron en la validación clínica del sistema. El acto se realizará dentro de los 30 días posteriores a la defensa oral. Los gastos del encuentro serán financiados íntegramente por el responsable del proyecto.

Referencias

[1] W. J. Dahl *et al.*

[2] L. N. Lyzwinski *et al.*

[3] M. Vitale *et al.*

[4] A. Myers, N. Johnston, V. Rathod, A. Gorban, N. Silberman, S. Guadarrama, G. Papandreou, J. Huang, and K. Murphy, "Im2Calories: Towards an automated mobile vision food diary," in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, Google, 2015.

[5] C. Liu, Y. Cao, Y. Luo, G. Chen, V. Sharma, L. Gu, and C. Kangas, "DeepFood: Deep learning-based food image recognition for computer-aided dietary assessment," 2016. arXiv:1606.05675.

[6] others

[7] M. Nakamura *et al.*

[8] others

[9] others

[10] others.

[11] others